

Podaci su preuzeti skriptom `scripts/download_statsbomb.R` iz StatsBomb Open Data repozitorijuma. Skripta za svaku od četiri lige (Premier League, La Liga, Ligue 1, Serie A) bira sezonu sa najvećim brojem odigranih utakmica i zatim naizmenično (round-robin) preuzima event podatke, kako bi lige bile ravnomerno zastupljene. Ukupno je preuzeto 1.517 utakmica, odnosno 4,25 GB sirovih JSON fajlova, po jedan fajl za svaku utakmicu, u direktorijumu `data/raw/statsbomb/events/`. Metapodaci na nivou utakmice (liga, datum, timovi, rezultat) sačuvani su u `data/raw/statsbomb/matches/all_matches_meta.csv`, a `downloaded_matches_manifest.csv` (1.517 redova) sadrži samo utakmice koje su zaista preuzete i koristi se kao referenca pri učitavanju. Nakon parsiranja, skup sadrži ukupno N event zapisa. Podaci su korišćeni u skladu sa licencom StatsBomb Open Data (nekomercijalna, istraživačka upotreba uz obaveznu atribuciju).

Tok obrade — Zatim je kreirana skripta za procesiranje podataka zasnovana na paketu `sparklyr`. Obrada se odvija u dva sloja: prvo se učitavaju svi JSON fajlovi i iz njih se, spljoštavanjem ugnježdene strukture, formira Parquet skup u `data/interim/events_flat`, gde jedan red odgovara jednom događaju iz utakmice. Iz tog sloja se potom čitaju događaji i agregiraju u tabelu `data/interim/player_features`, koja čuva statistiku igrača, pri čemu je ključ jednog reda kombinacija igrač + tim. Rezultat se na kraju prikuplja u R i izvozi u CSV.

match_end — Za svaki meč određuje trajanje kao maksimum vremena među **Half End** događajima, čime se dobija kraj poslednjeg poluvremena uključujući nadoknadu.

starters — Iz **Starting XI** događaja razbija niz `tactics.lineup` operacijom `explode`, dajući po 11 redova za svaki od dva tima, odnosno 22 startera po meču.

subs — Iz **Substitution** događaja izdvaja igrača koji izlazi, igrača koji ulazi i minut zamene u istoj kontinuiranoj vremenskoj skali kao i kraj meča.

minutes_match — Spaja dva slučaja: starteri igraju od početka do zamene ili do kraja meča, a rezerve od ulaska do kraja meča.

minutes_total — Sabira odigrane minute po ključu igrač–tim, tako da igrač koji je promenio klub u toku sezone daje dva zasebna reda.

pos_rank — Broji događaje po kombinaciji igrač–tim–pozicija i rangira pozicije po učestalosti, uz prozorsku funkciju koja računa ukupan broj događaja kao imenilac.

positions — Zadržava samo najčešću poziciju svakog igrača i uz nju čuva `pos_purity`, udeo te pozicije u ukupnom broju događaja, kao meru specijalizacije.

counts — Jednim prolazom kroz L1 sloj agregira sve sirove brojače (dodavanja, šutevi, odbrambene akcije, prostorne statistike) po ključu igrač–tim.

Izvršno okruženje — Analiza je sprovedena u Apache Spark verziji 3.5.8 (Hadoop 3 distribucija), instaliranoj lokalno preko paketa `sparklyr` i pokrenutoj u `local[*]` režimu, gde ulogu i drajvera i executora preuzima jedan JVM proces koji koristi sva raspoloživa jezgra mašine.

Konfiguracija — Drajveru je dodeljeno 8 GB memorije, ograničenje za rezultat vraćen u R sesiju postavljeno je na 2 GB, a broj particija pri shuffle operacijama smanjen je sa podrazumevanih 200 na 32, što je primerenije obimu podataka i izbegava nepotrebno usitnjavanje zadataka na jednoj mašini.

Formiranje ciljnog obeležja i provera kvaliteta labela

Ciljno obeležje za klasifikaciju formirano je preslikavanjem detaljnih StatsBomb pozicija u šest pozicionih klasa: GK, CB, FB, DM_CM, AM_W i FW. U skupu se pojavilo 22 od 24 moguće pozicije, a preslikavanje je dato u tabeli X. Pozicija igrača određena je kao modalna, odnosno ona u kojoj je zabeležen najveći broj njegovih događaja, uz istovremeno računanje mere čistoće — udela događaja odigranih u toj poziciji u odnosu na ukupan broj njegovih događaja.


Prvo izračunavanje čistoće, sprovedeno nad detaljnim pozicijama, dalo je medijanu 0,676, pri čemu je 456 redova (27%) imalo vrednost ispod 0,5. Ispitivanjem je utvrđeno da je reč o artefaktu granularnosti obeležja, a ne o stvarnoj neodređenosti uloge: rotacija između levog i desnog štopera, odnosno između levog i desnog centralnog veznog igrača, računa se kao nečistoća iako pozicijska klasa ostaje nepromenjena. Mera je zbog toga preračunata nad šest klasa, primenom istog upita uz prethodno preslikavanje pozicija na nivou pojedinačnih događaja.

Tabela Y — Raspodela mere čistoće po nivou agregacije

Nivo agregacije	Min	Q1	Medijana	Sredina a	Q3	Max	Udeo ispod 0,5
22 detaljne pozicije	0,194	0,487	0,676	0,687	0,923	1,000	456 (26,8%)
6 pozicionih klasa	0,389	0,855	0,979	0,904	1,000	1,000	25 (1,5%)

Na nivou šest klasa medijana čistoće iznosi 0,979, što znači da polovina igrača provodi gotovo sve svoje događaje u jednoj pozicionoj klasi, dok tri četvrtine njih ima čistoću iznad 0,855. Time je potvrđeno da je ciljno obeležje pouzdano i da eventualne greške klasifikacionih modela neće poticati od šuma u labelama.

Preostalih 25 redova sa čistoćom ispod 0,5 predstavljaju stvarne višepozicione igrače, čija uloga tokom sezone nije bila jednoznačno određena. Ti redovi nisu uklonjeni iz skupa, već su zadržani i korišćeni pri tumačenju grešaka u klasifikaciji (poglavlje Z).



slika 1: kako je zamišljena podela po pozicijama

Analiza nedostajućih vrednosti

Analiza je sprovedena nad skupom događaja (5.321.459 zapisa, 18 obeležja), a ne nad izvedenom tabelom na nivou igrača, jer se agregacijom u brojače nedostajuće vrednosti gube.

Profil po kolonama dat je u tabeli X. Pet obeležja nema nijednu nedostajuću vrednost, dok sedam ima udeo iznad 70%. Ipak, nijedna nedostajuća vrednost nije posledica greške u prikupljanju — sve se svrstavaju u četiri kategorije:

Strukturno odsustvo. Obeležja `shot_xg`, `shot_outcome`, `dribble_outcome`, `duel_type` i `pass_length` definisana su samo za odgovarajući tip događaja. Provera pokazuje savršeno poklapanje: `shot_xg` nedostaje u 5.283.571 zapisu, tačno onoliko koliko ima događaja koji nisu šut, a među 37.888 šuteva ne nedostaje nijednom.

Semantičko odsustvo. Kod `pass_outcome` odsustvo nosi informaciju — vrednost se upisuje samo kada dodavanje nije uspeo, pa NA označava uspeh. Od 1.481.813 dodavanja, 1.136.687 nema upisan ishod, što daje tačnost od 76,7%. Ovo je jedini slučaj u kojem bi naivno izostavljanje takvih zapisa dovelo do ozbiljne greške, tj. tačnosti od 0% za sve igrače.

Logičko odsustvo. Bulovska obeležja `pass_goal_assist` i `pass_shot_assist` upisuju se samo kada je uslov ispunjen, pa NA odgovara vrednosti netačno. Zabeleženo je 2.596 asistencija i 24.439 ključnih dodavanja.

Administrativni događaji. Zapisi poput `Half Start`, `Starting XI` i `Tactical Shift` opisuju tok utakmice, a ne akciju igrača: 20.393 (0,4%) bez igrača i 37.460 (0,7%) bez koordinata.

U skladu s tim, nijedna metoda imputacije nije primenjena. Brojači su formirani uslovnim sabiranjem po tipu događaja, čime strukturno odsustvo daje nulu; `pass_outcome IS NULL` iskorišćen je kao definicija uspešnog dodavanja; zapisi bez igrača isključeni su uslovom nad identifikatorom; a `AVG` i `STDDEV` zanemaruju nedostajuće koordinate. Konačna tabela na nivou igrača stoga ne sadrži nijednu nedostajuću vrednost.

4. Preliminarna analiza podataka

Analiza je sprovedena na dva nivoa: nad skupom događaja (5.321.459 zapisa) u sistemu Spark i nad izvedenom tabelom na nivou igrača (1.702 reda) u okruženju R. Podela odgovara načelu na kojem počiva paket `sparklyr` — obrada se izvršava u sistemu Spark, dok se u R prikupljaju samo agregirani rezultati.

4.1 Analiza nad skupom događaja


Zabeležena su 33 tipa događaja, pri čemu dodavanje, prijem lopte i vođenje lopte čine 74,8% svih zapisa.

event_type	n
<code><chr></code>	<code><dbl></code>
1 Pass	<u>1481</u> 813
2 Ball Receipt*	<u>1384</u> 869
3 Carry	<u>1117</u> 196
4 Pressure	<u>491</u> 104
5 Ball Recovery	<u>162</u> 682
6 Duel	<u>125</u> 123
7 Clearance	<u>73</u> 006
8 Block	<u>59</u> 169

tabela 1:proporcije tipova eventova

Za vizualizaciju raspodela korišćen je paket `dbplot`, koji raspodelu po intervalima izračunava u sistemu Spark i u R prenosi samo tabelu sa vrednostima po intervalima, čime je izbegnuto prenošenje 1,48 miliona pojedinačnih vrednosti radi crtanja histograma.


Raspodela dužine dodavanja izrazito je desno asimetrična, sa vrhom u opsegu kratkih dodavanja i repom koji odgovara dugim loptama i centaršutevima.



slika 2: Histogram dužine dodavanja


Gustina dodira po terenu izračunata je nad 5.283.999 zapisa sa koordinatama. Za prikaz po pozicionim klasama koordinate su svedene na mrežu koraka četiri jedinice, celobrojn timer deljenjem u okviru upita, čimer je skup sveden na nekoliko hiljada agregiranih ćelija pre

prenošenja u R.



slika 3: Gustina dodira po terenu

Prikaz po klasama pokazuje jasno razgraničene obrasce. Golmani su skoncentrisani isključivo u sopstvenom kaznenom prostoru. Štoperi imaju najveću gustinu ispred sopstvenog kaznenog prostora, uz slabo prisustvo u protivničkom, koje potiče od prekida. Bočni odbrambeni igrači formiraju obrazac duž bočnih linija, sa niskom gustinom u središtu. Vezni igrači imaju najpravnomerniju raspodelu, sa težištem duž središnje ose i oko centralnog kruga. Krilni igrači ponavljaju obrazac bočnih odbrambenih igrača, ali pomeren ka protivničkoj polovini. Napadači su skoncentrisani u protivničkom kaznenom prostoru.




slika 4: Gustina dodira po poziciji

Razlike među panelima uočljive su golim okom i predstavljaju prvu potvrdu da su pozicione klase razlučive iz podataka. Prikaz ujedno najavljuje gde se mogu očekivati greške u klasifikaciji. Na primer bočni odbrambeni i krilni igrači razlikuju se prevashodno po položaju duž dužine terena, a ne po obliku obrasca, dok se štoperi i defanzivni vezni igrači preklapaju ispred sopstvenog kaznenog prostora.

4.2 Deskriptivne statistike i raspodele

Za svako od 31 numeričkog obeležja izračunate su aritmetička sredina, medijana, standardna devijacija, minimum, maksimum i koeficijent asimetrije. Ispravnost tabele proverena je poređenjem graničnih vrednosti sa pojedinačnim slučajevima: najniža tačnost dodavanja iznosi 0,391 i pripada golmanu, što se poklapa sa vrednošću dobijenom u fazi pripreme podataka. Najširi raspon ima obeležje `mean_x`, od 7,18 do 86,47, čime pokriva praktično celu dužinu terena.

Raspodele svih obeležja date su na slici 5. Pozitivna asimetrija najizraženija je kod obeležja `goals_p90` (2,29), `xg_p90` (1,96) i `assists_p90` (1,87); kod postignutih golova aritmetička sredina iznosi 0,113, a medijana 0,054, što odražava stvarnu prirodu pojave — većina igrača postiže vrlo malo golova, dok mali broj napadača formira desni rep. Negativna asimetrija kod obeležja `sd_x` (-1,58) i `mean_x` (-1,08) posledica je prisustva golmana, koji imaju nisku prostornu disperziju i nizak prosečni položaj.




slika 5: Histogrami za svako obeležje

Transformacija obeležja nije sprovedena: stablo odlučivanja i slučajna šuma nisu osetljivi na monotone transformacije, dok se kod metode k najbližih suseda uticaj repova ublažava standardizacijom unutar cevovoda, u svakom preklopu unakrsne validacije.

4.3 Odnosi između obeležja

Izračunati su Pirsonovi koeficijenti korelacije za svih 465 parova obeležja, od kojih njih 16 ima apsolutnu vrednost iznad 0,8. Najjače veze su **d3_share–mean_x** (–0,980), **passes_completed_p90–passes_p90** (0,975) i **dribbles_completed_p90–dribbles_p90** (0,956).



slika 6: Pirsonovi koeficijenti korelacije


Na osnovu toga iz skupa za modelovanje uklonjena su obeležja **passes_completed_p90** i **dribbles_completed_p90**, koja predstavljaju proizvod odgovarajućeg brojača i procenta uspešnosti, pa nose informaciju već zastupljenu kroz dva druga obeležja. Kod metoda zasnovanih na rastojanju njihovo zadržavanje uzrokuje višestruko računanje iste veličine. Konačan skup sadrži 29 obeležja. Par **d3_share–mean_x** zadržan je u celini, jer nijedno od njih nije izvedeno iz drugog i oba su pri vrhu po diskriminativnoj moći; njihova redundansa obuhvaćena je scenarijem sa redukcijom dimenzionalnosti.

Za ocenu diskriminativne moći primenjena je jednofaktorska analiza varijanse sa pozicionom klasom kao faktorom (tabela 2). Četiri od pet najdiskriminativnijih obeležja su prostorne prirode. Najjače prostorno obeležje **d3_share** ($F = 8.586,5$) ima diskriminativnu moć 5,6 puta veću od najjačeg brojača događaja **clearances_p90** ($F = 1.523,1$). Pozicija igrača se, dakle, pouzdanije očitava iz toga gde se igrač kreće nego iz toga koje akcije izvodi. Prostorna obeležja nisu bila deo početne verzije tabele i uvedena su tek pri prelasku na obradu u sistemu Spark.

d3_share	mean_x	avg_pass_length	sd_x	f3_share
2451.9	8586.5	6953.7	3036.9	2601.0
clearances_p90	miscontrols_p90	pressures_p90	shots_p90	
691.0	1523.1	1069.5	719.6	695.4
xg_p90	dispossessed_p90			
	665.0	658.4		

tabela 2: Koja obeležja razdvajaju pozicije

Kutijasti dijagrami osam najdiskriminativnijih obeležja po klasama (slika 7) vizuelno potvrđuju ove rezultate.




slika 7: kutijasti dijagrami najdiskriminativnijih obeležja po klasama

4.4 Analiza glavnih komponentata

Nad standardizovanim skupom prva glavna komponenta objašnjava 37,6% varijanse, druga 18,7%, a treća 10,3%. Za obuhvatanje 90% varijanse potrebno je 11 komponentata, čime je brojčano potvrđena prethodno uočena redundansa. Prve dve komponente zajedno nose 56,3%, što je dovoljno za dvodimenzionalni prikaz (slika 4.5); isti prostor koristi se kasnije za

prikaz klastera, radi neposrednog poređenja pozicionih klasa i dobijenih grupa. Vrednost od 11 komponenata usvojena je kao parametar za scenario sa redukcijom dimenzionalnosti.



slika 8: Principal Component Analysis

Prve dve glavne komponente objašnjavaju 56,3% ukupne varijanse. Golmani se izdvajaju kao potpuno odvojena grupa, bez ijednog preklapanja sa ostalim klasama. Preostalih pet klasa formira kontinuum duž prve komponente, poređan od štopera preko bočnih odbrambenih i veznih igrača do krilnih igrača i napadača, bez oštarih granica među susednim klasama. Nalaz ukazuje da pozicione uloge u fudbalu nisu diskretne kategorije već tačke na spektru, pa se očekuje da greške klasifikacije budu skoncentrisane između susednih klasa na tom spektru.

5.2 Stablo odlučivanja

5.2.1 Postavka

Klasifikacioni cevovod formiran je funkcijom `ml_pipeline` i obuhvata četiri stadijuma. Prvi stadijum, `ft_string_indexer`, preslikava tekstualnu oznaku pozicione klase u brojčanu labelu, budući da biblioteka Spark MLlib ne prihvata tekstualne ciljne vrednosti. Drugi stadijum, `ft_vector_assembler`, objedinjuje 29 obeležja u jednu kolonu vektorskog tipa, što je format koji algoritmi iz te biblioteke očekuju. Treći stadijum, `ft_standard_scaler`,

sprovodi standardizaciju obeležja na nultu sredinu i jediničnu standardnu devijaciju. Četvrti stadijum je sam klasifikator, `ml_decision_tree_classifier`.

Standardizacija za stablo odlučivanja nije neophodna, jer se odluke o grananju donose poređenjem vrednosti sa pragovima, pa je metod nezavisan od skale obeležja. Zadržana je radi toga da sva tri klasifikaciona metoda koriste istovetan cevovod, čime se osigurava da razlike u rezultatima potiču isključivo od samih metoda.

Smeštanje standardizacije unutar cevovoda ima i metodološku posledicu. Pošto se ceo cevovod prosleđuje objektu za unakrsnu validaciju kao jedinstvena celina, parametri standardizacije prilagođavaju se iznova u svakom od deset preklopa, i to isključivo nad podacima za obučavanje u tom preklopu. Time je isključeno curenje informacija do kojeg bi došlo da je standardizacija sprovedena nad celim trening skupom pre podele na preklope.

Kao mera performansi u postupku izbora parametara korišćena je F1 mera, izračunata objektom `ml_multiclass_classification_evaluator`. Ta mera izabrana je umesto proste tačnosti zbog neuravnoteženosti klasa, gde odnos najbrojnije i najmanje brojne klase iznosi 2,9 : 1.

Unakrsna validacija sprovedena je sa deset preklopa, uz semenom fiksiran raspored i paralelno obučavanje četiri modela. Tri scenarija pokrenuta su kao tri odvojena postupka validacije, radi jasnog razdvajanja rezultata.

5.2.2 Scenario 1 — dubina stabla

Ispitano je šest vrednosti parametra `max_depth`, čime je obučeno 60 modela. Rezultati su dati u tabeli 5.1 i prikazani na slici 5.1.

Tabela 5.1 — Uticaj maksimalne dubine stabla na F1 meru

<code>max_depth</code>	F1
2	0,5299
3	0,8707
5	0,8844
8	0,8761
12	0,8661
20	0,8610

Kriva pokazuje jasno izražen kompromis između pristrasnosti i varijanse. Pri dubini 2 stablo raspolaže sa najviše četiri lista, što nije dovoljno za razlikovanje šest klasa, pa F1 mera pada na 0,5299. Prelaskom na dubinu 3 performanse naglo rastu, dostižu maksimum pri dubini 5, a nakon toga blago i postojano opadaju, što ukazuje na preprilagođavanje.

Razlika između najbolje i najniže vrednosti u opsegu upotrebljivih dubina iznosi svega 2,3 procentna poena, iz čega sledi da je metod u ispitanom opsegu stabilan. Vreme izvršavanja scenarija iznosilo je 80,4 sekunde.

5.2.3 Scenario 2 — uslovi zaustavljanja grananja

Ispitane su kombinacije parametara `min_instances_per_node` i `min_info_gain`, ukupno 15 kombinacija, odnosno 150 obučenih modela. Rezultati su dati u tabeli 5.2 i prikazani na slici 5.2.

Tabela 5.2 — F1 mera po kombinaciji uslova zaustavljanja grananja

<code>min_instances_per_node</code>	<code>min_info_gain</code> = 0	0,001	0,01
1	0,8844	0,8844	0,8852
5	0,8823	0,8823	0,8846
10	0,8732	0,8732	0,8732
20	0,8797	0,8797	0,8797
50	0,8707	0,8707	0,8707

Parametar `min_info_gain` praktično ne utiče na rezultat. Vrednosti 0 i 0,001 daju istovetne rezultate u svim slučajevima, dok vrednost 0,01 donosi razliku samo pri najmanjim vrednostima drugog parametra. Iz toga sledi da su grananja koja stablo bira već dovoljno informativna, pa prag prirasta informacije retko postaje aktivno ograničenje.

Povećanje minimalnog broja instanci u čvoru u celini smanjuje F1 meru, sa 0,8852 pri vrednosti 1 na 0,8707 pri vrednosti 50, mada opadanje nije strogo monotono — vrednost 20 daje nešto bolji rezultat od vrednosti 10. Ukupan raspon svih 15 kombinacija iznosi 1,5 procentnih poena, čime je potvrđeno da je metod neosetljiv na ova dva parametra u ispitanom opsegu. Vreme izvršavanja scenarija iznosilo je 182,3 sekunde.

5.2.4 Scenario 3 — kriterijum grananja

Upoređena su dva kriterijuma nečistoće, Gini indeks i entropija, pri tri različite dubine stabla, ukupno šest kombinacija i 60 obučenih modela. Rezultati su dati u tabeli 5.3 i prikazani na slici 5.3.

Tabela 5.3 — Poređenje kriterijuma nečistoće po dubini stabla

<code>max_depth</code>	Gini	Entropija
5	0,8844	0,8857

10	0,8739	0,8825
15	0,8610	0,8788

Entropija daje bolji rezultat pri svim ispitanim dubinama, pri čemu prednost raste sa dubinom stabla: 0,13 procentnih poena pri dubini 5, zatim 0,86 pri dubini 10 i 1,78 pri dubini 15. Objašnjenje je u tome što entropija jače kažnjava nečistoću čvora nego Gini indeks, pa pri većim dubinama, kada čvorovi obuhvataju manji broj primeraka, donosi opreznije odluke o grananju i sporije se prilagođava.

Pri manjim dubinama razlika je zanemarljiva, što je saglasno sa opšte prihvaćenim nalazom da izbor kriterijuma nečistoće retko bitno utiče na performanse stabla odlučivanja. Vreme izvršavanja scenarija iznosilo je 91,5 sekundi.

5.2.5 Izbor rešenja i ocena na test skupu

Poređenjem najboljih rezultata po scenarijima — 0,8844 za prvi, 0,8852 za drugi i 0,8857 za treći — izabran je model iz trećeg scenarija, sa kriterijumom entropije i maksimalnom dubinom 5. Kriterijum izbora bila je najviša prosečna F1 mera iz unakrsne validacije, uz pravilo da se pri približno jednakim vrednostima bira jednostavniji model.

Treba primetiti da se najbolji rezultati sva tri scenarija razlikuju za manje od 0,15 procentnih poena, iz čega sledi da izbor scenarija nije od suštinskog značaja i da je metod dostigao svoj plafon na raspoloživim podacima.

Izabrani model ocenjen je nad test skupom od 342 reda, koji do tog trenutka nije korišćen ni u jednoj fazi.

Tabela 5.4 — Pokazatelji performansi izabranog modela

Pokazatelj	Vrednost
F1 iz unakrsne validacije (10 preklopa)	0,8857
Tačnost na test skupu	0,9123
95% interval poverenja	(0,877 – 0,940)
Koenov koeficijent kapa	0,8926
Makro preciznost	0,9276
Makro odziv	0,9191
Makro F1	0,9226
Balansirana tačnost	0,9504
Ukupno vreme (tri scenarija)	354,2 s

Tačnost od 91,2% znatno nadmašuje stopu većinske klase od 21,6%, pri čemu je razlika statistički značajna uz $p < 0,001$. Vrednost Koenovog koeficijenta kapa od 0,8926 pokazuje gotovo savršeno slaganje sa stvarnim labelama, znatno iznad nivoa koji bi se mogao očekivati slučajnim pogađanjem.

Vrednost makro F1 mere nad test skupom (0,9226) veća je od vrednosti dobijene unakrsnom validacijom (0,8857). Razlika ne ukazuje na nepravilnost i ima dva izvora. Unakrsna validacija obučava svaki model nad devet desetina trening skupa, pa daje blago pesimističnu procenu u odnosu na konačni model obučen nad celim trening skupom. Osim toga, primenjene mere nisu istovetne: evaluator u sistemu Spark računa F1 meru ponderisanu brojem primeraka po klasi, dok je makro F1 prosta aritmetička sredina vrednosti po klasama, koju klasa golmana sa savršenim rezultatom podiže.

5.2.6 Performanse po klasama

Tabela 5.5 — Pokazatelji performansi po pozicionim klasama

Klasa	Preciznos t	Odziv	F1	Balansirana tačnost
GK	1,0000	1,0000	1,0000	1,0000
CB	1,0000	0,9333	0,9655	0,9667
FB	0,9683	0,9104	0,9385	0,9516
DM_CM	0,8415	0,9324	0,8846	0,9420
FW	0,9048	0,8636	0,8837	0,9251
AM_W	0,8514	0,8750	0,8630	0,9171

Klasa golmana klasifikovana je savršeno po svim pokazateljima. Taj rezultat ne predstavlja stvarno dostignuće modela: golmani imaju vrednosti obeležja koje se ne preklapaju ni sa jednom drugom klasom, što je uočljivo i na dijagramu glavnih komponenta, gde čine potpuno odvojenu grupu. Klasa se stoga u tumačenju ukupnih rezultata tretira kao trivijalna, uz napomenu da podiže vrednosti makro mera.

Najteža je klasa ofanzivnih veznih i krilnih igrača, sa F1 merom od 0,8630. Ta klasa greši u oba smera prema obema susednim klasama, prema centralnim veznim igračima i prema napadačima, što odgovara njenom položaju u sredini napadačkog dela spektra. Klasa defanzivnih i centralnih veznih igrača ima najnižu preciznost uz visok odziv, iz čega sledi da model ima sklonost da u nju svrstava granične slučajeve iz susednih klasa: od 82 predviđanja te klase, 13 je pogrešno.

5.2.7 Analiza grešaka

Matrica konfuzije nad test skupom data je u tabeli 5.6 i prikazana na slici 5.4. Od 342 primerka, tačno je klasifikovano 312, a pogrešno 30.

Tabela 5.6 — Matrica konfuzije nad test skupom (redovi: predviđeno, kolone: stvarno)

Predviđeno \ Stvarno	GK	CB	FB	DM_CM	AM_W	FW
GK	25	0	0	0	0	0
CB	0	56	0	0	0	0
FB	0	1	61	1	0	0
DM_CM	0	3	5	69	5	0
AM_W	0	0	1	4	63	6
FW	0	0	0	0	4	38

Raspodela grešaka po parovima klasa: AM_W i FW deset grešaka, DM_CM i AM_W devet, FB i DM_CM šest, CB i DM_CM tri, CB i FB jedna, FB i AM_W jedna, dok klasa golmana nema nijednu grešku ni u jednom smeru.

Osnovni nalaz jeste da se 29 od 30 grešaka javlja između klasa koje su susedne na spektru odbrana–napad. Jedini izuzetak jeste bočni odbrambeni igrač svrstan u klasu ofanzivnih veznih i krilnih igrača. Ni taj slučaj nije proizvoljan: u preliminarnoj analizi već je uočeno da bočni odbrambeni igrači i krila dele obrazac kretanja duž bočnih linija i razlikuju se prevashodno po položaju duž dužine terena, pa je reč o klasama koje su susedne po prostornom obrascu iako ih na spektru odbrana–napad razdvaja klasa veznih igrača. Nijedna greška ne meša klase sa suprotnih krajeva spektra — nema nijednog slučaja u kojem je štoper svrstan među napadače ili obrnuto. Nalaz je u potpunosti saglasan sa strukturom uočenom na dijagramu glavnih komponentata, gde klase formiraju kontinuum bez oštih granica.

U specifikaciji projekta pretpostavljeno je da će najčešće greške biti između srodnih pozicija, uz primer bekova i štopera. Hipoteza je potvrđena u opštem obliku, budući da sve greške zaista jesu između srodnih pozicija. Navedeni primer, međutim, nije potvrđen: par štoperi–bekovi ima svega jednu grešku i spada među najbolje razdvojene parove u skupu. Dominantne zabune javljaju se u napadačkom delu spektra, između krila i napadača, odnosno između centralnih i ofanzivnih veznih igrača.

Objašnjenje sledi iz prostornih obeležja, koja su se u preliminarnoj analizi pokazala kao najdiskriminativnija. Štoperi i bočni odbrambeni igrači jasno se razlikuju po položaju u odnosu na širinu terena, dok se ofanzivni vezni igrači, krila i napadači kreću u sličnim zonama i razlikuju se prevashodno po učestalosti pojedinih akcija, što predstavlja slabiji signal.

5.2.8 Struktura modela i značaj obeležja

Izabrano stablo ima dubinu 5 i ukupno 33 čvora, od čega 16 unutrašnjih grananja i 17 listova. Model je dovoljno mali da se u celini prikaže kao skup pravila odlučivanja, što predstavlja njegovu prednost pri tumačenju u odnosu na ansambl metode.

Tabela 5.7 — Značaj obeležja u izabranom stablu

Obeležje	Značaj	Rang po analizi varijanse
mean_x	0,6028	2.
sd_x	0,1218	4.
interceptions_p90	0,1012	van prvih dvanaest
d3_share	0,0702	1.
carries_p90	0,0278	van prvih dvanaest
shots_p90	0,0223	9.
mean_y	0,0175	van prvih dvanaest
pressures_p90	0,0146	8.

Prva četiri obeležja nose 89,6% ukupnog značaja. Poređenje sa rezultatima analize varijanse iz preliminarne analize otkriva dve pojave.

Prvo, korelisana obeležja se međusobno potiskuju. Obeležje **d3_share** bilo je najdiskriminativnije pojedinačno, ali korelira $-0,980$ sa obeležjem **mean_x**. Stablo pri prvom grananju bira **mean_x** i time iscrpljuje tu informaciju, pa **d3_share** u ostatku stabla ima malo šta da doda. Još izrazitiji je slučaj obeležja **avg_pass_length**, trećeg po analizi varijanse, koje se među značajnim obeležjima uopšte ne pojavljuje, budući da korelira $0,894$ sa **d3_share**, odnosno $-0,867$ sa **mean_x**.

Drugo, stablo nagrađuje dopunsku informaciju. Obeležje **interceptions_p90** nije bilo među prvih dvanaest po analizi varijanse, ali je treće po značaju u stablu. Razlog je što donosi informaciju koju prostorna obeležja ne sadrže: nakon što **mean_x** razdvoji igrače po dubini terena, broj presecanja razlikuje defanzivnog veznog igrača od bočnog odbrambenog igrača, koji se kreću na sličnoj udaljenosti od sopstvenog gola.

Zaključak je da analiza varijanse meri pojedinačnu diskriminativnu moć obeležja, dok značaj obeležja u stablu meri njegov doprinos u prisustvu svih ostalih obeležja. Dve mere odgovaraju na različita pitanja, pa je njihovo neslaganje očekivano.